Solución a la Guía de Aprendizaje N.° 1: Datos, Información, Toma de Decisiones, Fuentes y Formatos

Matihas Alejandro Lopez Posada

Servicio Nacional de Aprendizaje (SENA)

Centro de Materiales y Ensayos

Programa de formación: Procesamiento de datos para modelos en la inteligencia artificial

Ficha: 3602991

Instructora: Nathalia Marcela Martinez Vargas

27 de octubre de 2026

Tabla de Contenido

- 1 Presentación 3
- 2 Actividades 3
  - 2.1 Actividades de reflexión inicial 3
    - 2.1.1 Actividades a Desarrollar (Caso PHE UK COVID-19) ... 3
  - 2.2 Actividades de contextualización e identificación de conocimientos ... 5
    - Eje temático y clasificación de fuentes 5
    - Listado de conjuntos de datos explorados 5
    - Tabla 1. Clasificación estadística de variables 6
  - 2.3 Actividades de Apropiación del Conocimiento (Auditoría Técnica) ... 8
    - Auditoría sobre el Dataset CSV 8
    - Auditoría sobre el Dataset XLSX 9

- 2.4 Actividades de Transferencia de Conocimiento 10
  - 2.4.1 Desarrollo del Diccionario de Datos 10
  - Tabla 2. Diccionario de datos del dataset principal ... 10
- 3 Condiciones de Entrega y Declaración de IA 12
- Referencias 13

Solución a la Guía de Aprendizaje N.° 1: Datos, Información, Toma de Decisiones, Fuentes y Formatos

1 Presentación

El análisis de datos estratégico requiere de un procesamiento riguroso que garantice que los datos crudos se transforman de forma precisa e íntegra en información útil para la toma de decisiones. El presente documento desarrolla las actividades planteadas en la Guía de Aprendizaje N.° 1, abarcando desde la reflexión crítica sobre fallas en la gestión de formatos estructurales de datos hasta la construcción práctica de herramientas de metadatos (diccionarios de datos) y auditorías de calidad de información.

---

2 Actividades

2.1 Actividades de reflexión inicial

2.1.1 Actividades a Desarrollar (Caso PHE UK COVID-19)

Diferencias estructurales entre archivos CSV, XLS y XLSX, límites de almacenamiento y fallo de integridad:

Diferencias entre formatos de archivos

Existen tres formatos principales para almacenar información, cada uno con características y propósitos distintos.

CSV

Es un archivo de texto plano donde la información se organiza línea por línea, separando cada campo por una coma, punto y coma o tabulación. No permite guardar colores, fórmulas, gráficos ni múltiples hojas de trabajo. Su ventaja principal es que es un archivo sumamente ligero, consume muy pocos recursos del sistema y es compatible con casi cualquier programa o lenguaje de programación.

XLS

Es el formato binario tradicional utilizado por las versiones antiguas de Microsoft Excel. Permite manejar múltiples hojas, fórmulas, gráficos y diseños visuales. Al ser un archivo binario cerrado, tiende a ser más pesado, consume más memoria en el equipo y tiene mayor riesgo de corromperse en comparación con los formatos modernos.

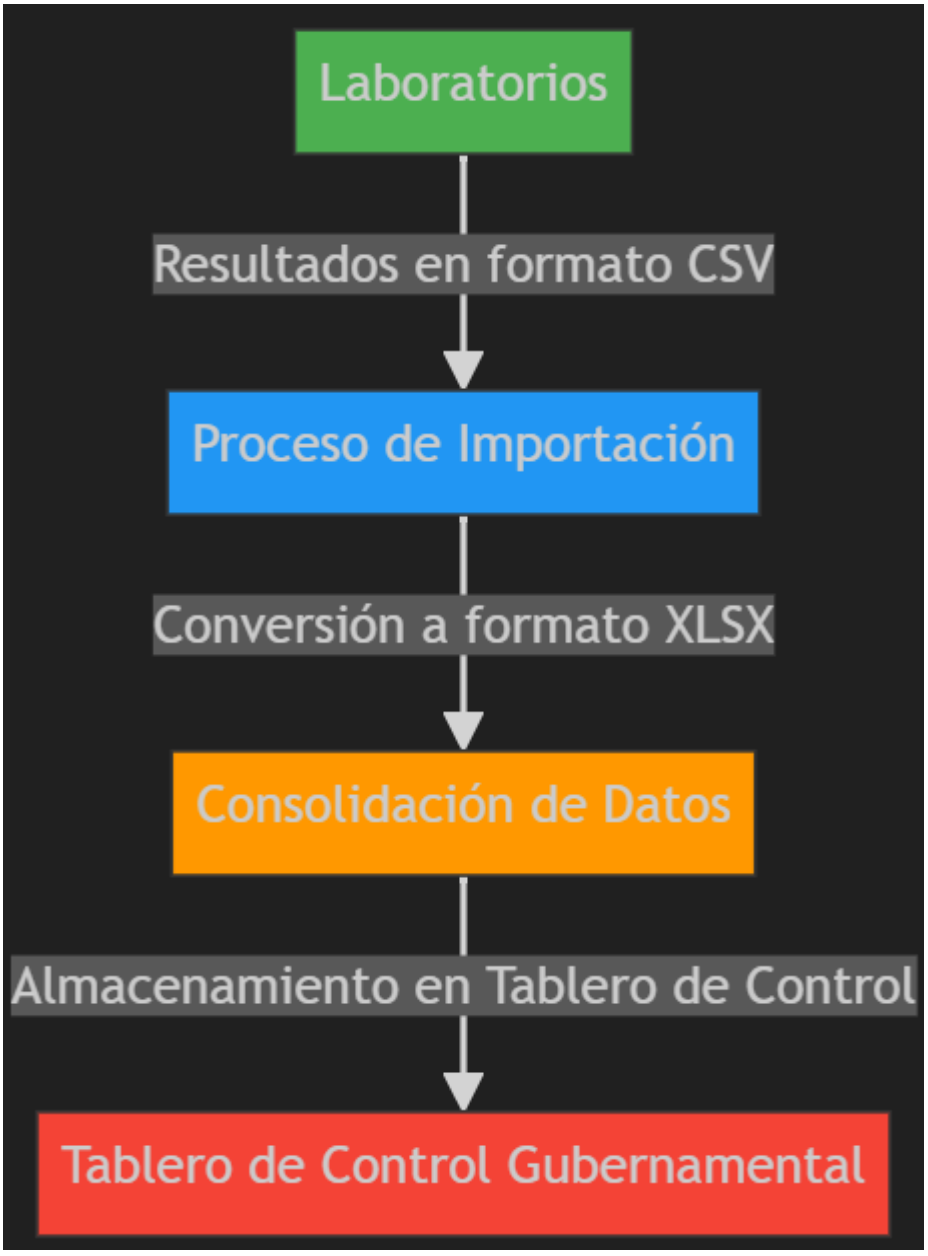
XLSX

Es el formato estándar moderno de Excel. Funciona como una carpeta comprimida estructurada en lenguaje XML. Permite guardar fórmulas, gráficos, múltiples hojas y estilos visuales complejos. Su compresión hace que sea más liviano que el formato antiguo, más seguro ante fallas de lectura y mucho más fácil de recuperar en caso de que el archivo sufra algún daño.

El punto de fallo en la integridad de los Datos

Este fallo ocurrió cuando el sistema automatizado utilizó el formato heredado xls que limitaba el numero de filas a 65, 536. Esto resultó en la pérdida de 15841 resultados positivos del COVID-19, ya que los datos que excedieron este límite no se registraron.

Esquema conceptual del tránsito seguro de información:



Justificación de los Formatos

Desde los Laboratorios hasta el Proceso de Importación:

Formato: CSV.

Justificación: El formato CSV es ideal para la transferencia de datos porque es simple, ligero y permite la exportación rápida de grandes volúmenes de datos sin complicaciones de formato. Además, es ampliamente compatible con diferentes sistemas.

Desde el Proceso de Importación hasta la Consolidación de Datos:

Formato: XLSX.

Justificación: El uso del formato XLSX en esta etapa es crucial, ya que permite manejar un mayor número de filas y columnas (hasta 1,048,576 filas y 16,384 columnas). Esto previene la pérdida de datos, ya que el sistema no se verá limitado por el número de filas como sucedió con el formato XLS. Además, XLSX ofrece mejores capacidades de manejo de datos y fórmulas.

Desde la Consolidación de Datos hasta el Tablero de Control:

Formato: XLSX.

Justificación: Mantener el formato XLSX en esta etapa asegura que la información presentada en el tablero de control sea completa y precisa. Esto es fundamental para la toma de decisiones informadas por parte de los responsables de la salud pública, evitando errores en la interpretación de los datos.

Conclusión

Este esquema conceptual ilustra claramente cómo debió ser el tránsito seguro de la información desde los laboratorios hasta el tablero de control gubernamental, utilizando los formatos adecuados para garantizar la preservación de todos los registros y evitar incidentes como la pérdida de 15,841 resultados positivos.

Conclusión analítica sobre el conocimiento técnico y la responsabilidad ética:

Existe una conexión vital entre el conocimiento técnico del analista de datos y sus obligaciones éticas al asistir en el proceso de toma de decisiones gubernamentales y de gestión.Las decisiones estratégicas dependen completamente de la veracidad de la información proporcionada a través de los dashboards.La ignorancia de algunos aspectos técnicos como los formatos de archivo o el corte de datos en un script de integración no solo constituye un error operativo sino también una negligencia profesional con consecuencias muy reales.En el sector público y en el campo de la salud los errores en el diseño del sistema de procesamiento de datos afectan directamente a las personas al no poder rastrear a tiempo más de 50.000 contactos cercanos de pacientes infectados.El analista de datos es responsable de auditar todo el sistema,de verificar las limitaciones de escalabilidad de los pipelines de datos que utiliza y de implementar mecanismos de alerta para las anomalías.La ética en la ciencia de datos significa que los modelos y los informes creados deben corresponder con la realidad.

2.2 Actividades de contextualización e identificación de conocimientos

Eje temático y clasificación de fuentes

- **Eje temático concertado:** Salud mental, el estado de la depresión en colombia y el poco apoyo que se brinda al mismo.
- **Justificación de la elección:** La salud mental en colombia está en unos de sus puntos mas bajos en estos últimos años, según la defensoría del pueblo el 4,7% de la población sufre depresión, lo que equivale a alrededor de 2,5 millones de personas que conviven con este trastorno; este problema no se trata correctamente y esto hace que el problema siga creciendo en vez de mitigarse.

Clasificación de fuentes de extracción

El equipo clasifica los conjuntos de datos recopilados como **fuentes de extracción secundarias**. Esta categorización se fundamenta en que los datos no fueron recolectados directamente de primera mano por nuestro equipo a través de sensores o encuestas en

campo, sino que corresponden a registros administrativos, tabulaciones y agregaciones previamente procesadas y publicadas por entidades oficiales e investigativas (como datos abiertos bogota) a través de sus portales institucionales de datos abiertos.

Listado de conjuntos de datos explorados

1. **Intervenciones de la linea 106(El poder de ser escuchado BOGOTA D.C):** Portal de alojamiento: *Datos Abiertos Bogotá* | URL: https://datosabiertos.bogota.gov.co/dataset/intervenciones-linea-106-el-poder-de-ser-escuchado-en-bogota-d-c
2. **salud mental en adultos mayores(Morbilidad atendida en salud mental en persona mayor en Bogota D.C):** Portal de alojamiento: *Datos Abiertos Colombia* | URL: https://datosabiertos.bogota.gov.co/dataset/salud-mental-en-adultos-mayores-en-bogota-d-c
3. **salud mental en adultos mayores(Violencia intrafamiliar persona mayor en Bogota D.C):** Portal de alojamiento: *Datos Abiertos Colombia* | URL: https://datosabiertos.bogota.gov.co/dataset/salud-mental-en-adultos-mayores-en-bogota-d-c

Tabla 1. Clasificación estadística de variables

Nota: La presente tabla extrae 30 variables de los datasets seleccionados y las clasifica acorde a la teoría estadística (Cualitativa Nominal u Ordinal; Cuantitativa Discreta o Continua).

#	***Nombre de la Tabla***	***Variable***	***Tipo de Variable***	***Subclasificación***
1	*Salud Mental - Línea 106*	*Mes*	*Cualitativa*	*Ordinal*
2	*Salud Mental - Línea 106*	*Año*	*Cuantitativa*	*Discreta*

3	*Salud Mental - Línea 106*	*Canal de contacto*	*Cualitativa*	*Nominal*
4	*Salud Mental - Línea 106*	*Curso de vida*	*Cualitativa*	*Ordinal*
5	*Salud Mental - Línea 106*	*Sexo*	*Cualitativa*	*Nominal*
6	*Salud Mental - Línea 106*	*Localidad*	*Cualitativa*	*Nominal*
7	*Salud Mental - Línea 106*	*Motivo*	*Cualitativa*	*Nominal*
8	*Salud Mental - Línea 106*	*Conteo*	*Cuantitativa*	*Discreta*
9	*Violencia Intrafamiliar*	*Año*	*Cuantitativa*	*Discreta*
10	*Violencia Intrafamiliar*	*Nombre de localidad*	*Cualitativa*	*Nominal*
11	*Violencia Intrafamiliar*	*Sexo*	*Cualitativa*	*Nominal*
12	*Violencia Intrafamiliar*	*Relación con el agresor*	*Cualitativa*	*Nominal*
13	*Violencia Intrafamiliar*	*Lugar de ocurrencia: Emocional*	*Cualitativa*	*Nominal*
14	*Violencia Intrafamiliar*	*Lugar de ocurrencia: Sexual*	*Cualitativa*	*Nominal*
15	*Violencia Intrafamiliar*	*Lugar de ocurrencia: Física*	*Cualitativa*	*Nominal*
16	*Violencia Intrafamiliar*	*Lugar de ocurrencia: Abandono*	*Cualitativa*	*Nominal*
17	*Violencia Intrafamiliar*	*Lugar de ocurrencia: Negligencia*	*Cualitativa*	*Nominal*

18	*Violencia Intrafamiliar*	*Lugar de ocurrencia: Económica*	*Cualitativa*	*Nominal*
19	*Violencia Intrafamiliar*	*Grupo poblacional: Discapacidad*	*Boleana*	*Boleana*
20	*Violencia Intrafamiliar*	*Grupo poblacional: Desmovilizados*	*Boleana*	*Boleana*
21	*Violencia Intrafamiliar*	*Grupo poblacional: Habitante de calle*	*Boleana*	*Boleana*
22	*Violencia Intrafamiliar*	*Grupo poblacional: Migrantes*	*Boleana*	*Boleana*
23	*Violencia Intrafamiliar*	*Grupo poblacional: Conflicto armado*	*Boleana*	*Boleana*
24	*Violencia Intrafamiliar*	*Grupo poblacional: Madre comunitaria*	*Boleana*	*Boleana*
25	*Violencia Intrafamiliar*	*Grupo poblacional: Gestante*	*Boleana*	*Boleana*
26	*Violencia Intrafamiliar*	*Grupo poblacional: Desplazado*	*Boleana*	*Boleana*
27	*Violencia Intrafamiliar*	*Grupo poblacional: Enfermo mental*	*Boleana*	*Boleana*
28	*Violencia Intrafamiliar*	*Grupo poblacional: ICBF*	*Boleana*	*Boleana*
29	*Violencia Intrafamiliar*	*Grupo poblacional: Cárcel*	*Boleana*	*Boleana*
30	*Violencia*	*Grupo poblacional:*	*Boleana*	*Boleana*

	Intrafamiliar	*Otros*		

2.3 Actividades de Apropiación del Conocimiento (Auditoría Técnica)

Se ejecutó una auditoría técnica de calidad de datos sobre los siguientes archivos del eje temático:

- **Dataset formato CSV:** https://datosabiertos.bogota.gov.co/dataset/intervenciones-linea-106-el-poder-de-ser-escuchado-en-bogota-d-c
- **Dataset formato XLSX:** https://www.datos.gov.co/en/Salud-y-Protecci-n-Social/Salud-Mental/d53j-hn85/data_preview

-

Análisis de los problemas de calidad de los datos

1. Falta de uniformidad en mayúsculas y minúsculas

Se identificó una inconsistencia en la forma de escribir algunos datos, especialmente en la columna correspondiente a los meses. Por ejemplo, el mes «octubre» aparece completamente en minúsculas, mientras que los demás tienen la primera letra en mayúscula.

Este problema se detectó mediante una revisión visual de la información. Aunque parece un detalle menor, puede generar inconvenientes al momento de organizar, filtrar o agrupar los datos, ya que algunos programas pueden reconocer estos valores como categorías diferentes.

Como ejemplo, se encuentran los registros de «octubre» escritos en minúsculas frente a los demás meses que utilizan mayúscula inicial.

2. Uso irregular de caracteres especiales, guiones y tildes

Se encontraron algunos registros que utilizan símbolos, guiones y caracteres especiales de manera irregular, sin mantener un formato uniforme en toda la base de datos.

Esto se identificó al revisar las celdas correspondientes a nombres de categorías y ubicaciones, donde aparecen símbolos y espacios adicionales. Esta situación puede dificultar la organización de la información y su procesamiento mediante herramientas de análisis.

Un ejemplo de ello son los registros de ubicación escritos como «- FUERA DE BOGOTÁ -», en los cuales se podrían eliminar los guiones y espacios innecesarios para mantener una presentación más organizada.

3. Presencia de registros duplicados

Durante la revisión de la base de datos se encontraron varias filas que contienen exactamente la misma información en todas sus columnas. Estos registros aparecen repetidos, incluso en bloques consecutivos.

La presencia de datos duplicados puede afectar los resultados de los análisis estadísticos, debido a que aumenta artificialmente la cantidad de registros y puede generar resultados incorrectos al realizar conteos o calcular frecuencias.

Como ejemplo, se identificaron filas repetidas que contienen los mismos valores de mes, año, canal, curso de vida y sexo.

4. Uso de comas dentro de una misma celda

Se identificó que algunas celdas contienen comas dentro de sus descripciones, especialmente en los registros relacionados con los motivos de consulta.

Aunque esto no representa necesariamente un error en Excel, puede generar dificultades al exportar o procesar la información en formato CSV si no se configuran correctamente los separadores. Por esta razón, es importante tener en cuenta este aspecto al momento de trabajar con los datos en otras herramientas.

Un ejemplo es la categoría «Autoimagen, autoconcepto y autoestima», en la cual se utilizan comas para separar diferentes conceptos dentro de una misma celda.

5. Textos demasiado largos en algunas celdas

Se observó que algunas celdas contienen descripciones bastante extensas que no se visualizan completamente debido al ancho de las columnas.

Este aspecto se identificó al revisar la presentación de la tabla, donde algunos textos aparecen cortados o no se muestran en su totalidad. Esto puede dificultar la lectura y generar confusiones al momento de consultar o interpretar la información.

Un ejemplo son las descripciones de los motivos de atención, cuyo contenido no se alcanza a visualizar completamente cuando las columnas tienen un ancho reducido.

6. Presencia de celdas vacías

Durante la revisión de los registros también se encontraron algunas celdas que no contienen información, a pesar de encontrarse dentro de columnas que incluyen datos en otros registros.

Esta situación puede dificultar ciertos cálculos y análisis estadísticos, especialmente cuando se utilizan fórmulas o gráficos que requieren información completa. Sin embargo, es necesario revisar cada caso para determinar si se trata de información faltante o de campos que no necesitan ser diligenciados.

Como ejemplo, se encuentran algunos registros en los que las columnas de seguimiento o información complementaria aparecen sin ningún valor.

2.4 Actividades de Transferencia de Conocimiento

2.4.1 Desarrollo del Diccionario de Datos

Para documentar la estructura técnica del conjunto de datos seleccionado como más robusto (https://datosabiertos.bogota.gov.co/dataset/salud-mental-en-adultos-mayores-en-bogota-d-c

), el equipo elaboró la siguiente matriz formal de metadatos.

Tabla 2. Diccionario de datos del dataset principal

(Se encuentra adjunto aparte de este documento)

Declaración sobre el uso de Inteligencia Artificial

De acuerdo con las indicaciones establecidas en la guía de trabajo, se presenta la siguiente declaración sobre el uso de herramientas de Inteligencia Artificial (IA) durante el desarrollo del proyecto.

Herramientas de IA consultadas

- ChatGPT.
- Gemini.
- Monica.

Uso de la Inteligencia Artificial durante el desarrollo del trabajo

Estructuración general de la guía. Se utilizó Gemini como herramienta de apoyo para establecer una estructura inicial del documento y obtener una referencia sobre la organización y el desarrollo de los diferentes apartados.

Uso estimado de IA: 80 %.

Punto 2.1.1. Se utilizó IA para revisar errores ortográficos, mejorar la redacción y ajustar algunas expresiones personales a un lenguaje más formal y apropiado para el contexto académico, conservando las ideas originales.

Uso estimado de IA: 40 %.

Punto 2.2. Se utilizó IA como apoyo para reorganizar y dar formato a la estructura de una tabla. El diligenciamiento y desarrollo de su contenido fue realizado directamente por el equipo de trabajo.

Uso estimado de IA: 30 %.

Punto 2.3. Se empleó IA para facilitar la identificación de posibles inconsistencias y errores de manera masiva en diferentes conjuntos de datos. A partir de los resultados obtenidos, se realizó una revisión y selección propia de los problemas que se consideraron relevantes para incluir en el trabajo.

Uso estimado de IA: 60 %.

Punto 2.4. Se utilizó IA como herramienta de apoyo para la construcción inicial y organización del diccionario de datos. Posteriormente, el equipo realizó revisiones, correcciones, ajustes en las descripciones y ampliaciones de contenido, con el propósito de mejorar la precisión y adaptar el resultado a las características de la base de datos analizada.

Uso estimado de IA: 70 %.

Ajustes finales del documento. Se recurrió a herramientas de IA para realizar correcciones ortográficas, mejorar algunos aspectos de la redacción, ajustar expresiones para lograr una mayor claridad y organizar el documento de acuerdo con las normas APA (séptima edición).

Uso estimado de IA: 30 %.

Participación del equipo de trabajo

Las herramientas de Inteligencia Artificial se utilizaron como apoyo durante diferentes etapas del proyecto, principalmente en tareas de organización, revisión, identificación de inconsistencias y presentación de la información. Sin embargo, la selección de los conjuntos de datos, la revisión de los resultados, la toma de decisiones, la selección de los errores relevantes y los ajustes finales del contenido fueron realizados directamente por el equipo de trabajo.

Nota. Los porcentajes presentados corresponden a estimaciones aproximadas del nivel de apoyo recibido mediante herramientas de Inteligencia Artificial en cada actividad. No representan una medición exacta de autoría o contribución.

-

Referencias

Datos Abiertos Bogotá. (s. f.). *Plataforma Distrital de Datos Abiertos*. Recuperado el 26 de octubre de 2026, de https://datosabiertos.bogota.gov.co/

Datos Abiertos Colombia. (s. f.). *Portal de Datos Abiertos de Colombia*. Recuperado el 26 de octubre de 2026, de https://www.datos.gov.co/

Portal Nacional de Datos Abiertos. (s. f.). *Salud mental* [Conjunto de datos]. Gobierno de Colombia. https://www.datos.gov.co/en/Salud-y-Protecci-n-Social/Salud-Mental/d53j-hn85